


Redes neuronales

Andrés Daniel Godoy Ortiz


Muchos recursos tomados de 3blue1Brown y Emergent Garden



Datos, lista de medidas o


Percepciones


Andrés Daniel Godoy Ortiz




Predicción o
conceptos

Una sola neurona, una entrada una salida







PERCEPTION SPACE





Las mediciones de la realidad (datos) son vectores del espacio de percepciones o características

Entrenar una neurona significa, mover esa línea
O hiperplano (olvidémonos por un segundo de la
función de activación.

Ajustar la separación del espacio de
características.





¿Un hiperplano? ¿por qué?

¿Cómo lo represento
matemáticamente?


En \mathbb{R}^n , un **hiperplano** es un subespacio de dimensión $n - 1$.
Su ecuación general es:


$$\mathbf{w}^\top \mathbf{x} + b = 0$$

Este hiperplano **divide** el espacio en dos mitades:

- Si $\mathbf{w}^\top \mathbf{x} + b > 0$, estás en un lado.
- Si $\mathbf{w}^\top \mathbf{x} + b < 0$, estás en el otro.

Tenemos entonces un
producto escalar, es decir, la
magnitud de proyectar un
vector sobre otro






$$\mathbf{w}^T \mathbf{x} = -b$$

Si ves a $\mathbf{w}^T \mathbf{x}$ como una proyección de \mathbf{x} en la dirección de \mathbf{w} , entonces estás diciendo: "Todos los puntos \mathbf{x} cuya proyección en la dirección de \mathbf{w} dan el mismo resultado ($-b$) están en el hiperplano".


$$N(x) = wx + b$$


$$w = 0.50$$

$$b = 0.00$$



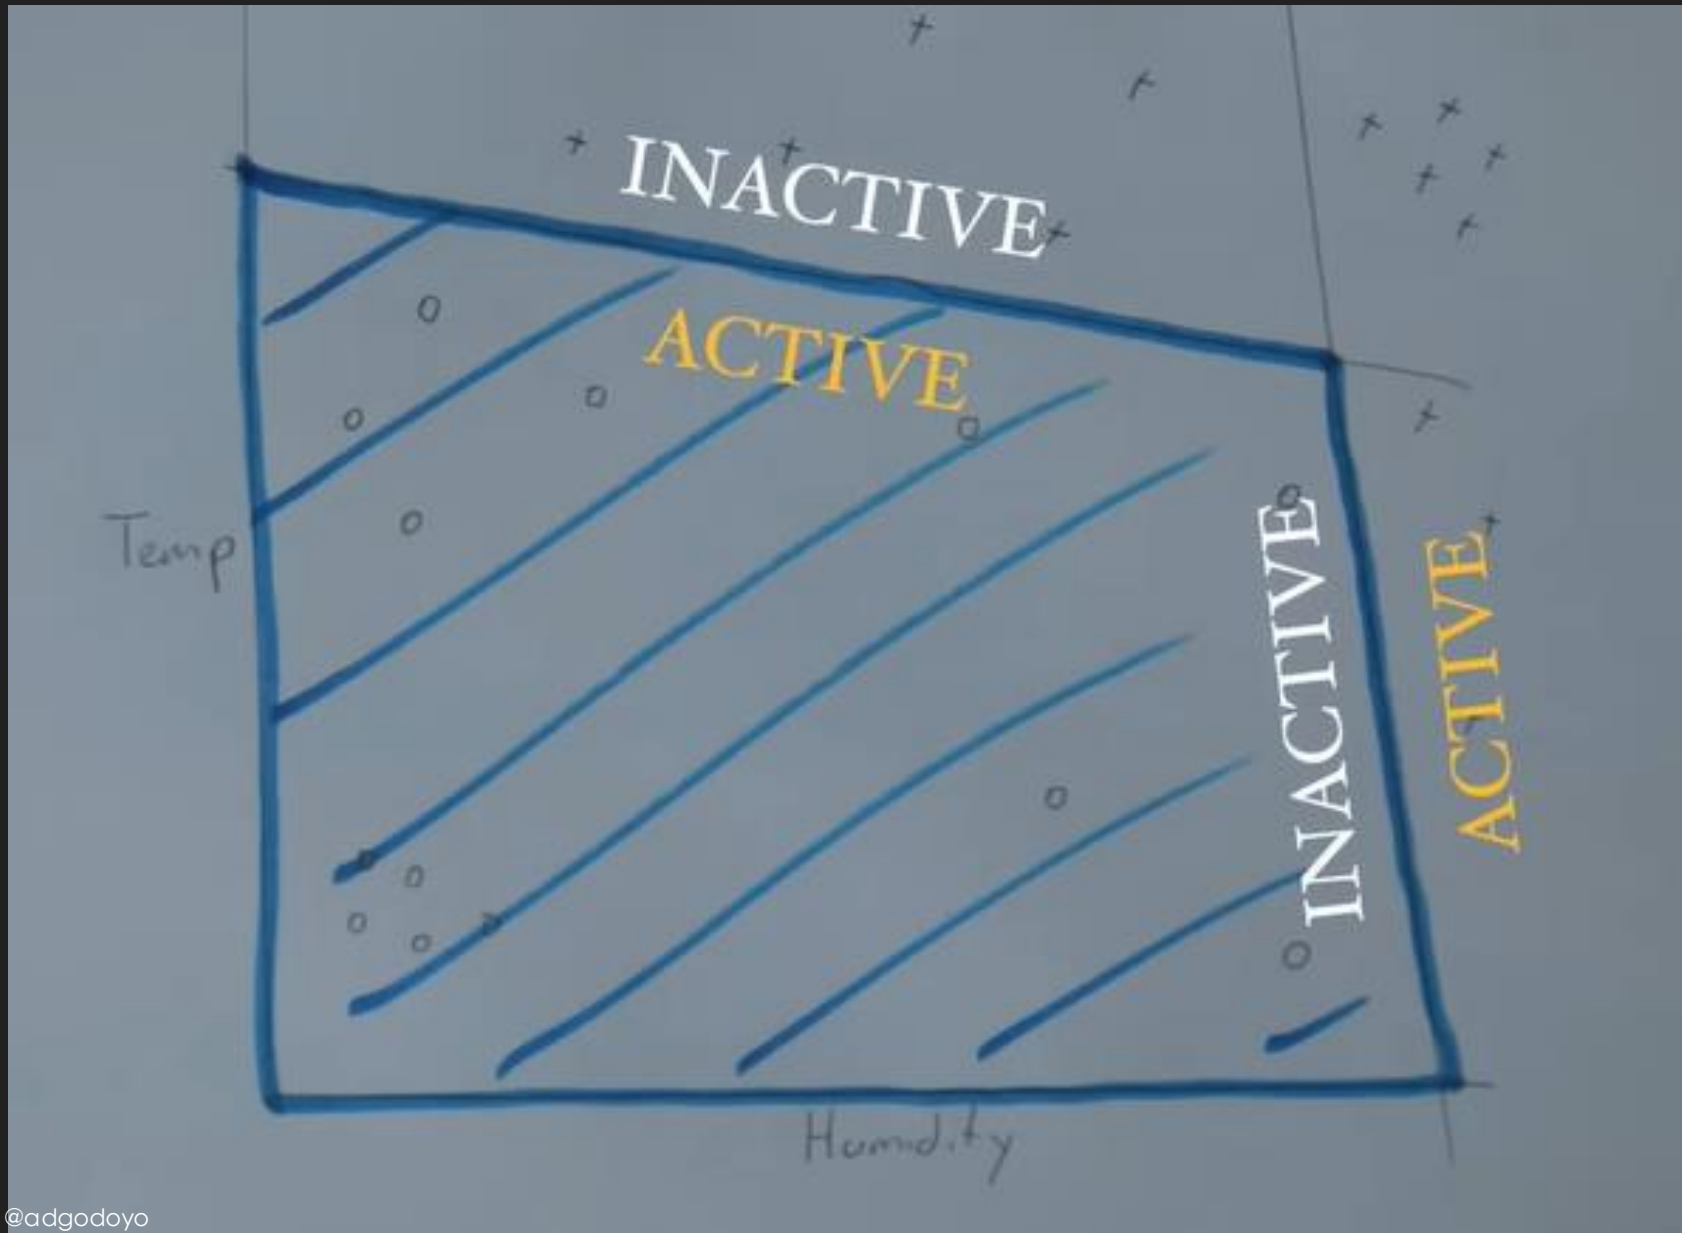
Cada neurona va a ser una función afín dentro una función no línea

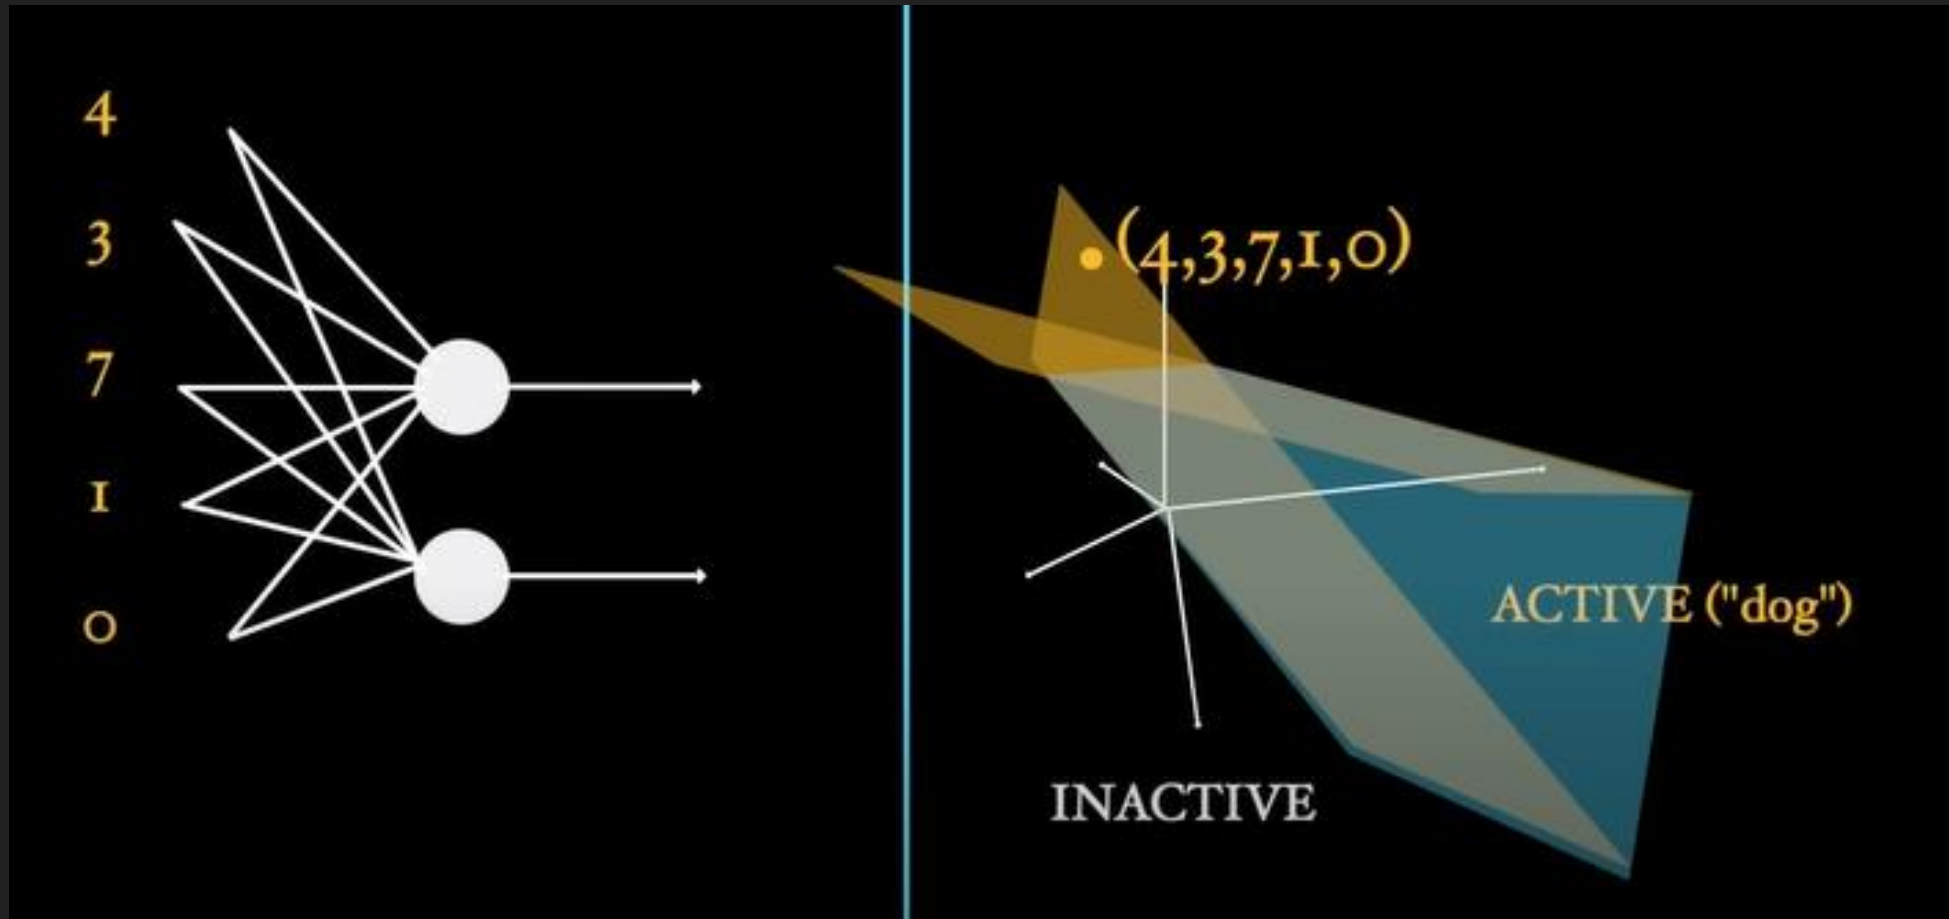








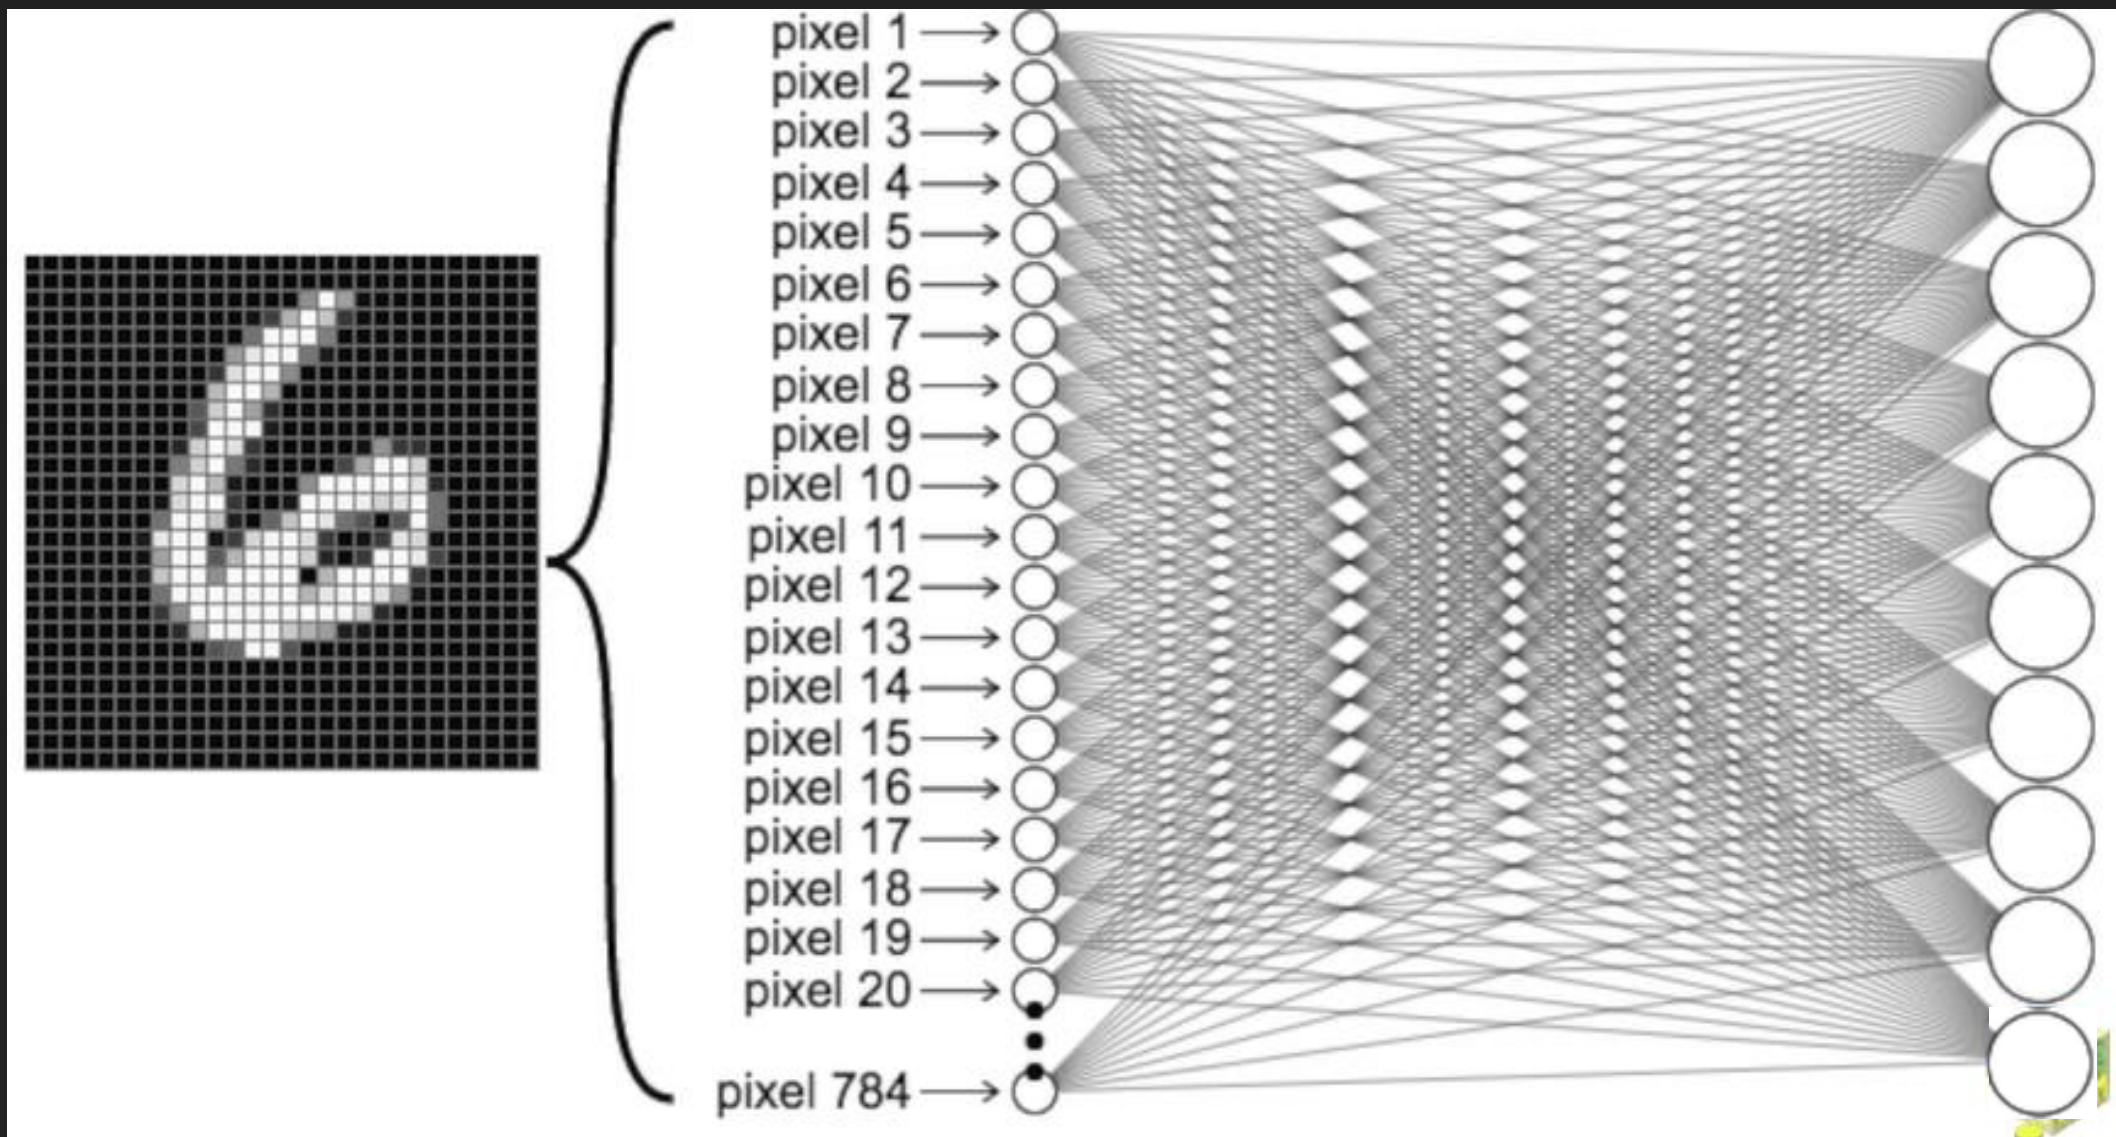




Los **conceptos o predicciones** son particiones o regiones del espacio de características, divididas por esa hipersuperficie.

En problemas de regresión, la idea es estar siempre sobre la hipersuperficie (solo hay una neurona al final).


3 8 9 0 5 7 4 8 5 1 9 6 6 8 5 1 8 3 2 0 2 9 3 5 0 3 4 8 7 3 3 1 5
5 6 6 7 5 2 4 6 1 3 4 7 7 9 6 0 3 1 9 8 3 2 9 8 1 4 2 2 0 2 3 2 6
4 6 8 3 2 4 7 1 1 6 7 8 0 0 4 9 5 4 6 3 4 3 2 6 2 5 1 2 6 6 8 4 7
9 4 4 0 3 0 6 1 7 3 1 9 1 1 7 3 7 2 0 9 5 5 8 2 3 6 9 1 8 3 6 5 8
5 2 0 2 7 7 5 9 6 3 9 0 2 2 6 3 1 0 1 5 6 5 1 6 4 7 4 2 2 3 5 6 9
9 6 1 9 2 2 4 8 6 2 1 1 3 3 2 4 6 0 3 5 7 9 4 2 5 8 9 8 6 0 4 7 0
3 9 2 0 1 8 1 9 6 2 7 2 4 4 2 4 1 7 0 2 8 4 3 8 6 9 1 6 3 1 0 8 1
1 2 8 6 0 3 9 2 8 6 1 3 5 5 0 0 0 8 2 6 9 2 5 1 9 0 3 5 9 4 9 1 2
9 8 4 6 1 0 9 3 2 9 4 4 0 6 9 6 9 4 7 8 0 1 2 7 0 1 9 1 3 7 1 7 3
0 5 5 0 8 2 5 2 9 0 5 1 7 4 2 6 6 5 4 1 9 9 5 1 2 2 6 2 8 7 2 4
9 4 2 3 4 7 7 5 7 6 0 6 2 8 0 5 2 4 7 9 2 3 2 0 2 3 0 7 8 0 2 4 5
7 5 7 6 5 8 8 9 7 5 4 7 8 9 1 4 5 9 6 1 3 9 5 1 3 4 6 2 6 3 9 1 6
5 7 8 7 2 4 0 4 4 5 1 8 9 3 2 2 4 3 2 7 4 2 8 1 4 5 0 1 1 1 1 4 7
4 9 1 7 8 0 1 2 0 3 7 9 1 5 3 3 2 8 9 1 5 0 9 3 7 6 4 3 7 9 5 1 8
9 9 1 2 2 8 3 1 2 3 5 7 4 3 4 4 3 4 1 2 6 6 5 2 8 7 0 9 4 0 1 4 9
2 9 3 8 8 4 6 9 4 8 7 4 0 2 5 6 4 7 9 3 7 0 0 4 1 8 6 3 8 1 3 9 0
0 2 0 6 3 4 1 4 2 1 1 2 9 9 6 0 4 2 0 5 8 4 1 9 3 9 0 8 8 9 2 6 1



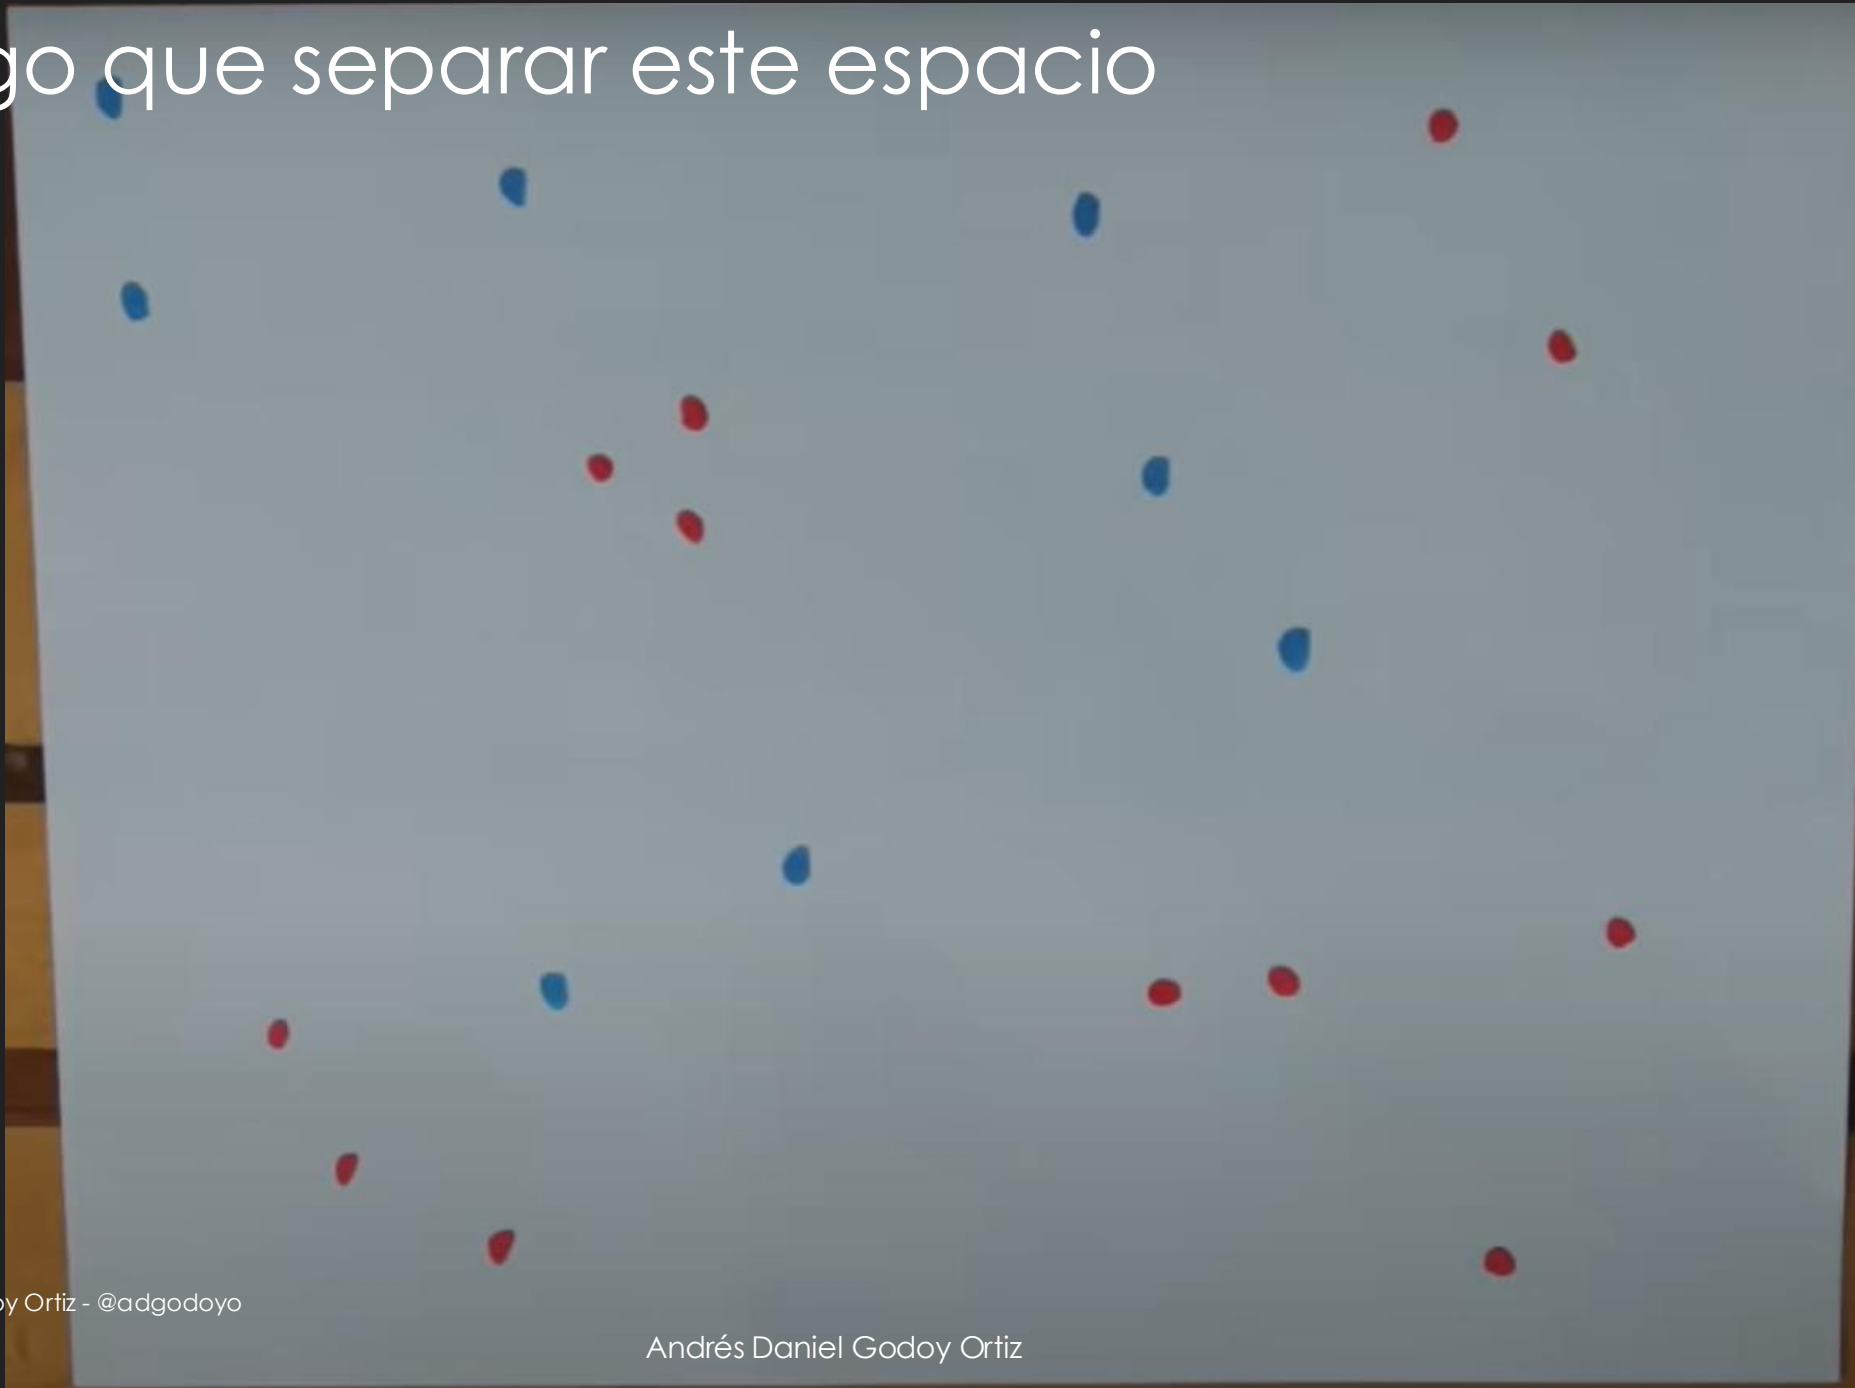


Dividir el espacio con una o varias líneas sería poco exitoso en el ejemplo anterior.


Así que vamos a entrar en la parte MENOS COMPRENDIDA de las redes neuronales: Capas múltiples



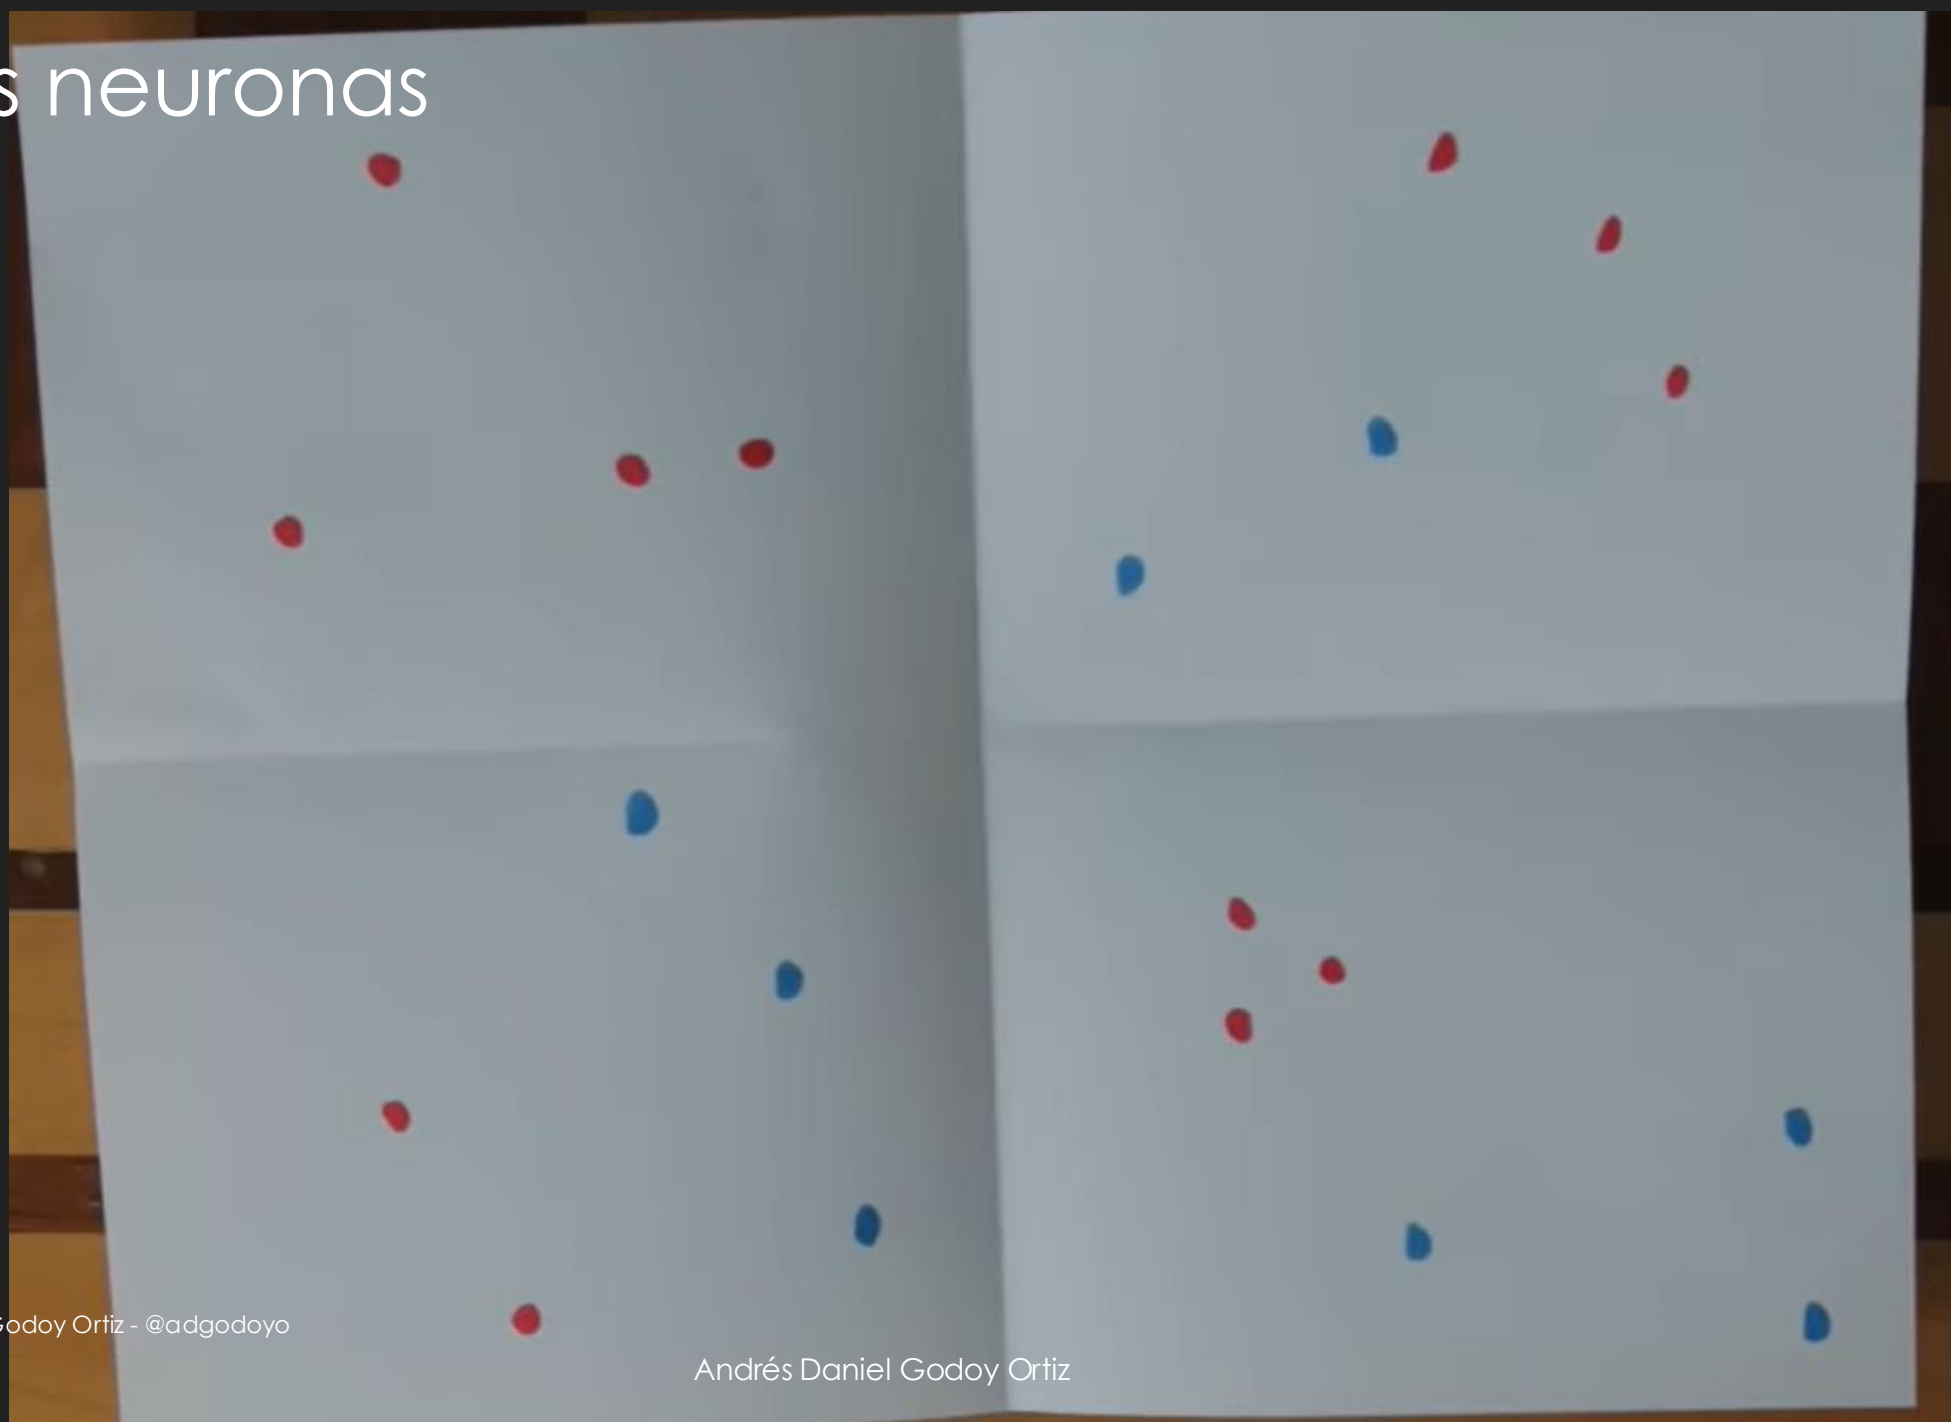
Tengo que separar este espacio




Una neurona





Dos neuronas




Seis neuronas, seis “dobleces”









Tres neuronas, seis “dobleces”



Cuatro “dobleces”, 16 regiones
Cinco “dobleces”, 32 regiones
Seis “dobleces”, 64 regiones y
así...crece exponencialmente







Palm trees




Wheels



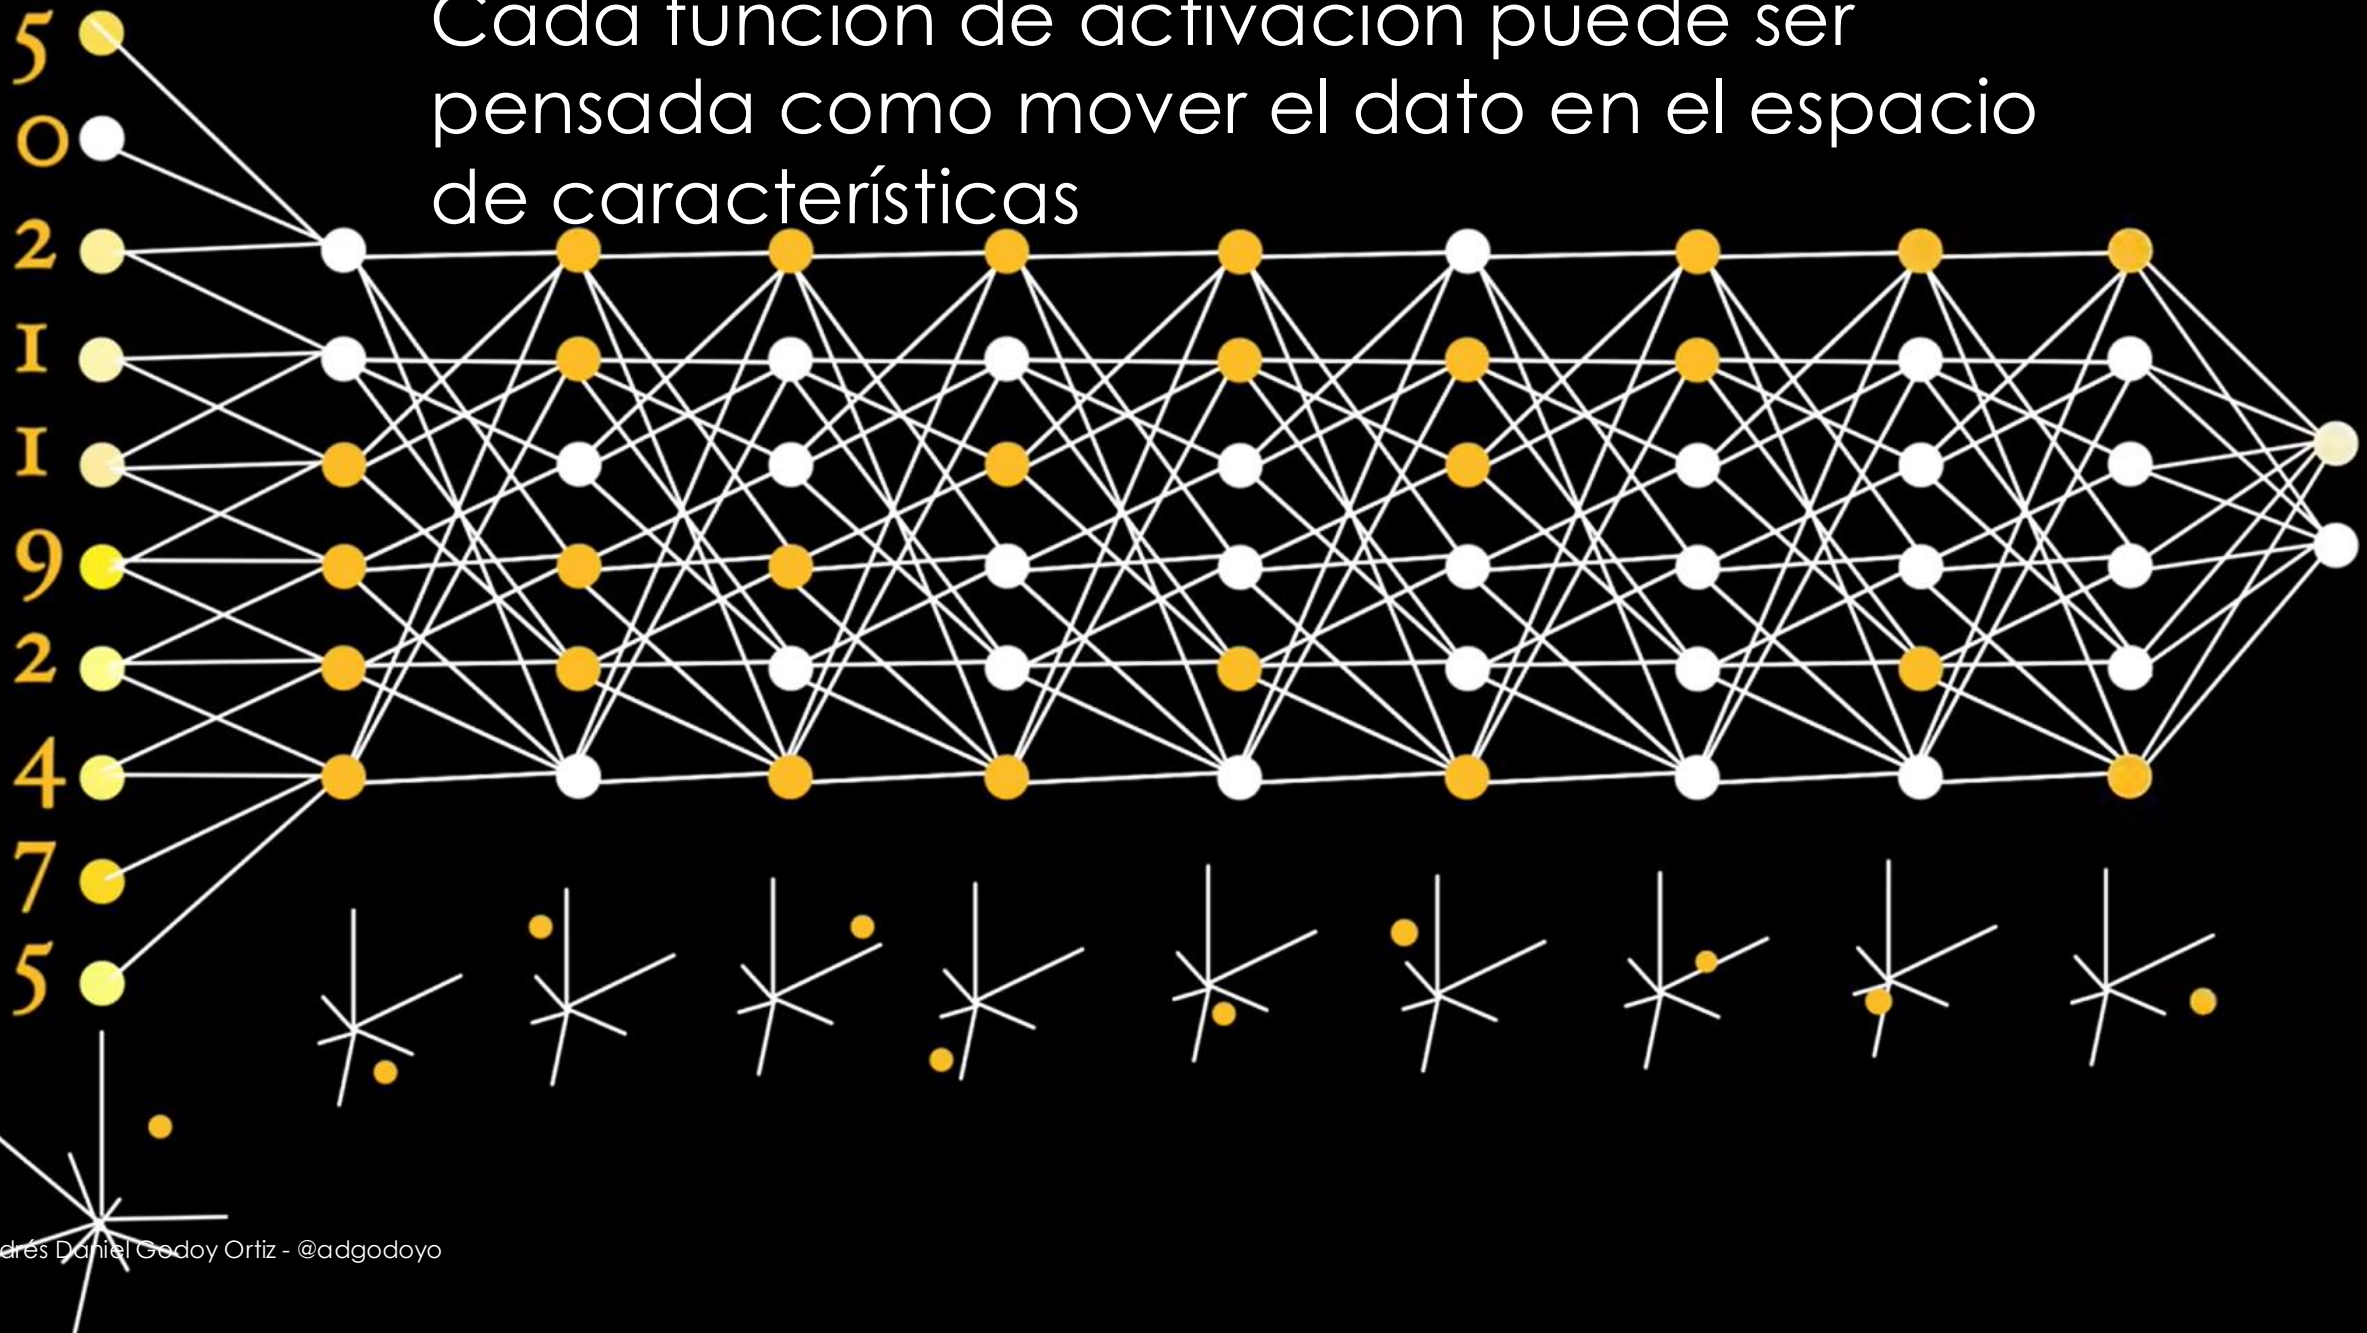
Dogs on leash



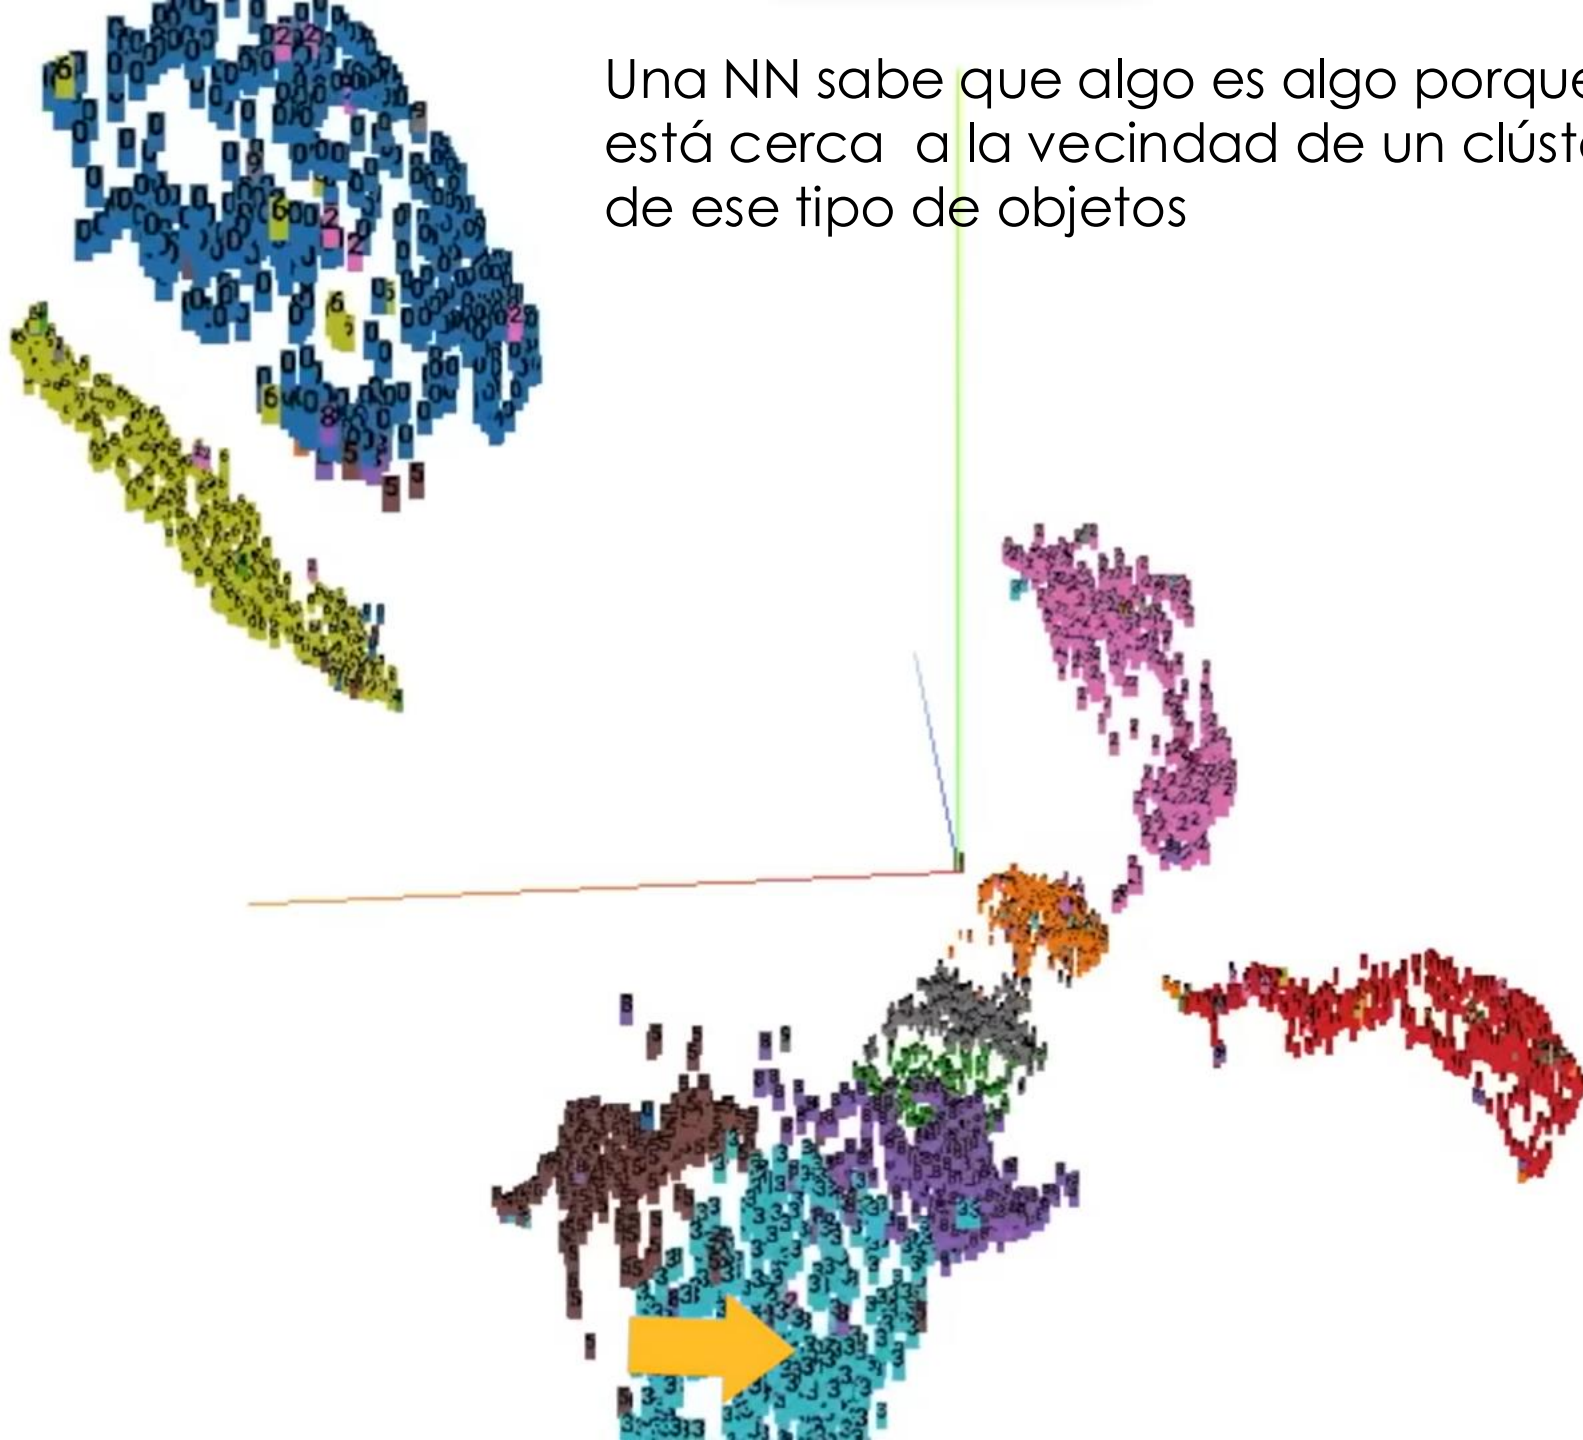
Houses




Cada función de activación puede ser pensada como mover el dato en el espacio de características




Una NN sabe que algo es algo porque
está cerca a la vecindad de un clúster
de ese tipo de objetos



Problema de regresión:





Supón una red con varias capas, pero **sin función de activación**, es decir, solo transformaciones lineales:

$$f(\mathbf{x}) = \mathbf{W}^{(3)} \left(\mathbf{W}^{(2)} \left(\mathbf{W}^{(1)} \mathbf{x} + \mathbf{b}^{(1)} \right) + \mathbf{b}^{(2)} \right) + \mathbf{b}^{(3)}$$

Pero... ¡la composición de funciones lineales es otra función lineal! Entonces:

$$f(\mathbf{x}) = \mathbf{W}\mathbf{x} + \mathbf{b}$$


La función de activación
permite transformaciones no
lineales

$$\text{ReLU}(x) = \text{MAX}(x, 0)$$

$$N(x) = \text{MAX}(wx + b, 0)$$

$$w = 0.50$$

$$b = 0.00$$



$$\begin{aligned}
& -\max(-5x + -7.7, 0) + \\
& -\max(-1.2x + -1.3, 0) + \\
& -\max(1.2x + 1, 0) + \\
& \max(1.2x + -0.2, 0) + \\
& \max(2x + -1.1, 0) + \\
& \max(5x + -5, 0)
\end{aligned}$$



Dot Product


$$\begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ 1 \end{bmatrix} \cdot \begin{bmatrix} w_1 \\ w_2 \\ w_3 \\ w_4 \end{bmatrix}$$


Dot Product

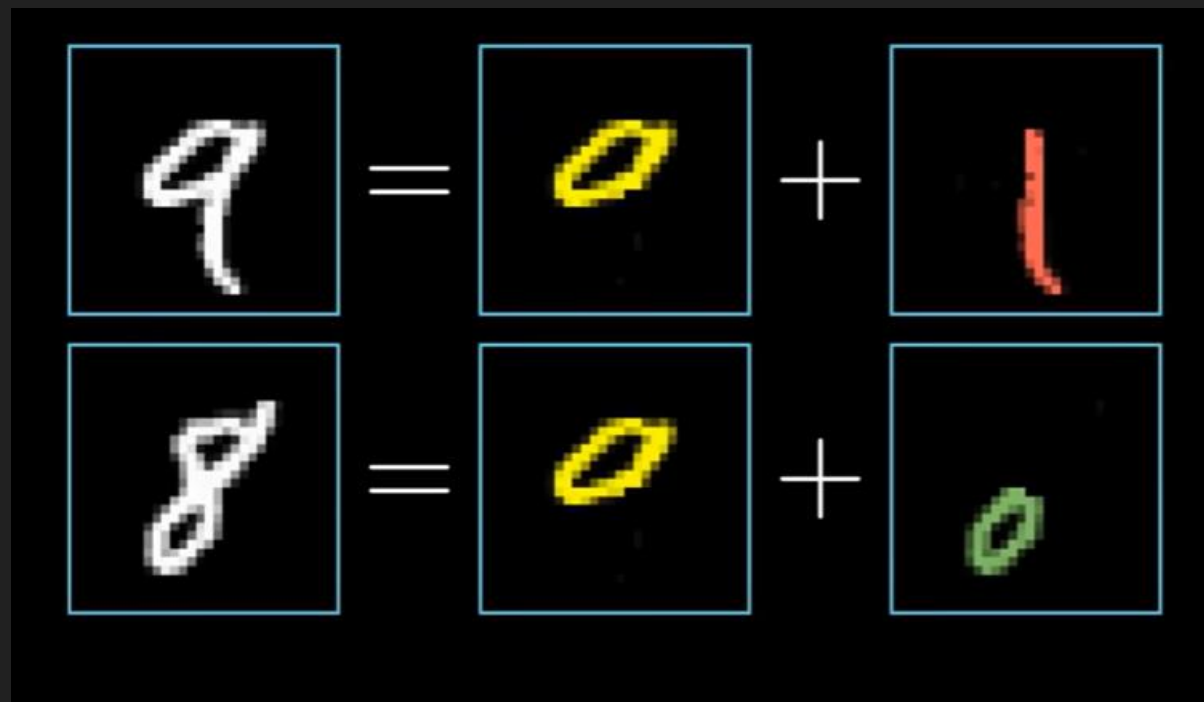
$$\begin{bmatrix} 0.3 \\ 1.8 \\ 0.5 \\ 1.0 \end{bmatrix} \cdot \begin{bmatrix} 0.2 \\ -0.4 \\ 0.6 \\ 0.1 \end{bmatrix} = -0.26$$

$$\text{ReLU}(-0.26)$$


Vamos a pensar entonces
que una neurona es un
número y ya...










784








¿Qué parámetros?


¿Qué pesos debería tener mi red neuronal para detectar un objeto como el de la imagen?




Se quisiera que los pixeles en blanco (cuyo valor podemos pensar como 1 y 0 si el pixel es negro), tuvieran un peso muy alto.


Por otro lado, los pixeles circundantes deberían tener un peso incluso negativo.

De forma que justo cuando la red “vea” ese objeto, de como resultado final el valor más alto. Si ve otro objeto, daría un valor bajo.



Otra vez, vamos a pensar
entonces que una neurona es
un número y ya...





Una neurona:

$$a_0^{(1)} = \sigma \left(w_{0,0} a_0^{(0)} + w_{0,1} a_1^{(0)} + \dots + w_{0,n} a_n^{(0)} + b_0 \right)$$

Una capa de neuronas:

$$\sigma \left(\begin{bmatrix} w_{0,0} & w_{0,1} & \dots & w_{0,n} \\ w_{1,0} & w_{1,1} & \dots & w_{1,n} \\ \vdots & \vdots & \ddots & \vdots \\ w_{k,0} & w_{k,1} & \dots & w_{k,n} \end{bmatrix} \begin{bmatrix} a_0^{(0)} \\ a_1^{(0)} \\ \vdots \\ a_n^{(0)} \end{bmatrix} + \begin{bmatrix} b_0 \\ b_1 \\ \vdots \\ b_n \end{bmatrix} \right)$$

Notación compacta:

$$\mathbf{a}^{(1)} = \sigma(\mathbf{W}\mathbf{a}^{(0)} + \mathbf{b})$$

¿Cómo aprende la red?

Gradiente Descendente

¿Cómo encuentro el gradiente?

Backpropagation



Gracias

adgodoyo@gmail.com

Andrés Daniel Godoy Ortiz - @adgodoyo